Autor: Martín de las Heras

Práctica 2

En primer lugar, importamos todas las librerías que vamos a necesitar:

In [ ]:
```
import pandas as pd
import numpy as np
from matplotlib import pyplot as plt
from sklearn.model_selection import train_test_split
import statsmodels.api as sm
import seaborn as sns
from sklearn.preprocessing import PolynomialFeatures
```

Ejercicio 1

Un distribuidor de cervezas especiales está interesado en el efecto del precio de la botella de PARADISE PREMIUM BEER sobre la cantidad demandada de botellas al mes. Por esta razón, se han recogido los datos de 10 meses seleccionados al azar sobre las variables X: precio fijado por el distribuidor, en euros, para la botella de PPB durante un mes e Y: cantidad demandada de botellas de PPB, en unidades de millar, en el mismo mes:

In [ ]:
```
X = [1.35, 0.95, 1.1, 1.6, 1.25, 0.8, 1, 1.5, 1.15, 1.45]
Y = [33.2, 38.9, 36.3, 27.4, 33.7, 39.8, 37.2, 29.6, 36.5, 30.7]
```

a) ¿Por qué está situación se puede considerar un caso particular del modelo AS-RLS?

Porque se trata de una relación lineal entre la variable X y la variable Y, de manera que estimando la pendiente de la recta y su punto de intercepción con el eje y se puede predecir con un cierto margen de error las ventas en el futuro en base al precio de venta.

b) Dibuja el diagrama de dispersión con la recta de regresión ajustada. Extraer conclusiones.

In [ ]:
```
X_train, X_test, Y_train, Y_test = train_test_split(X, Y,
                                        # train_size   = 0.8,
                                        random_state = 1234
                                    )

# Creación del modelo utilizando matrices como en scikitlearn
# ==============================================================================
# A la matriz de predictores se le tiene que añadir una columna de 1s para el in
X_train = sm.add_constant(X_train, prepend=True)
modelo = sm.OLS(endog=Y_train, exog=X_train,)
modelo = modelo.fit()
print(modelo.summary())
modelo.conf_int(alpha=0.05)

# Predicciones con intervalo de confianza del 95%
# ==============================================================================
```

```python
predicciones = modelo.get_prediction(exog=X_train).summary_frame(alpha=0.05)
predicciones['x'] = X_train[:, 1]
predicciones = predicciones.sort_values('x')

# Gráfico del modelo
# ==============================================================================
plt.scatter(X, Y, marker='o', color = "gray")
plt.plot(predicciones['x'], predicciones["mean"], linestyle='-', label="OLS", co
plt.plot(predicciones['x'], predicciones["mean_ci_lower"], linestyle='--', color
plt.plot(predicciones['x'], predicciones["mean_ci_upper"], linestyle='--', color
plt.fill_between(predicciones['x'], predicciones["mean_ci_lower"], predicciones[
plt.legend();
```

```
C:\Users\Marti\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.11_qbz5n2
kfra8p0\LocalCache\local-packages\Python311\site-packages\statsmodels\stats\statt
ools.py:74: ValueWarning: omni_normtest is not valid with less than 8 observation
s; 7 samples were given.
  warn("omni_normtest is not valid with less than 8 observations; %i "
```

OLS Regression Results

Dep. Variable:	y	R-squared:	0.958
Model:	OLS	Adj. R-squared:	0.949
Method:	Least Squares	F-statistic:	113.1
Date:	Fri, 10 Nov 2023	Prob (F-statistic):	0.000127
Time:	18:13:29	Log-Likelihood:	-8.4287
No. Observations:	7	AIC:	20.86
Df Residuals:	5	BIC:	20.75
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	53.0103	1.709	31.019	0.000	48.617	57.403
x1	-15.3546	1.444	-10.636	0.000	-19.065	-11.644

Omnibus:	nan	Durbin-Watson:	0.674
Prob(Omnibus):	nan	Jarque-Bera (JB):	0.664
Skew:	0.100	Prob(JB):	0.718
Kurtosis:	1.505	Cond. No.	9.50

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

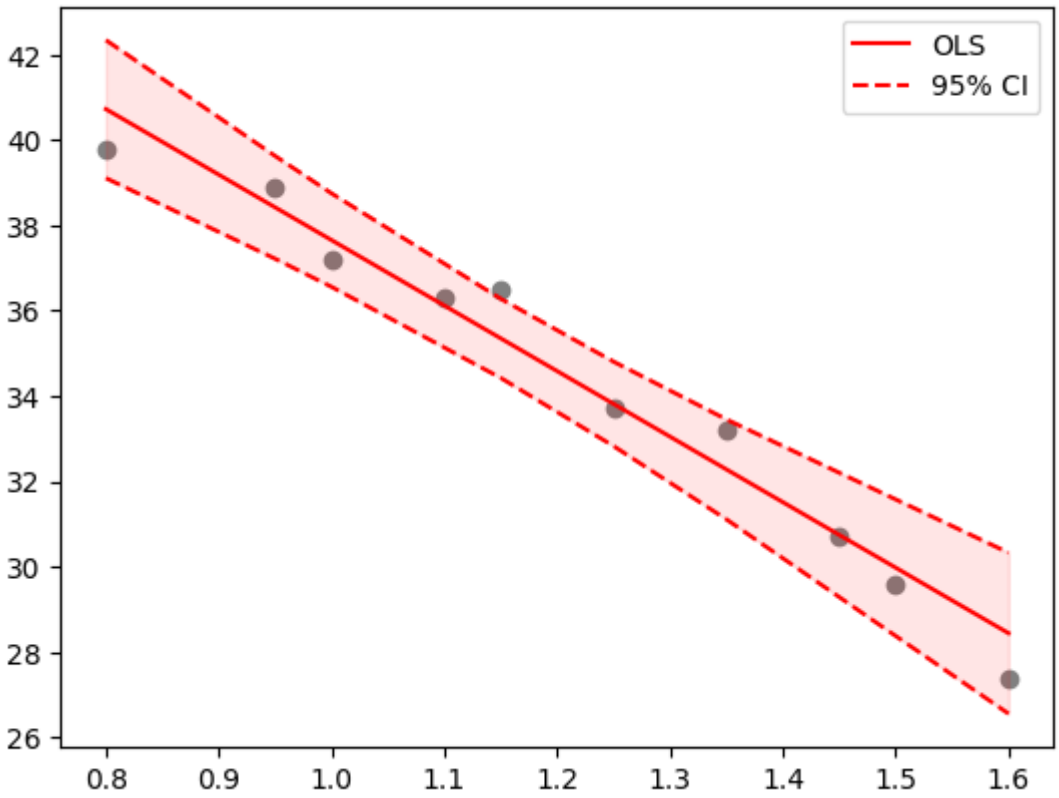

Podemos ver claramente que se trata de una relación inversa, donde a mayor precio de la botella, menos cantidad se vende. Esto se ve ya que la recta tiene una pendiente descendiente.

c) Obtener los residuos y proceder a un análisis gráfico de los mismos. Extraer conclusiones sobre el modelo AS-RLS basado en normalidad, aleatoriedad y homocedasticidad de los errores.

In [ ]:
```
# Diagnóstico errores (residuos) de las predicciones de entrenamiento
# ======================================================================

prediccion_train = modelo.predict(exog = X_train)
residuos_train   = prediccion_train - Y_train

# Gráficos
# ======================================================================
fig, axes = plt.subplots(nrows=3, ncols=2, figsize=(9, 8))

axes[0, 0].scatter(Y_train, prediccion_train, edgecolors=(0, 0, 0), alpha = 0.4)
axes[0, 0].plot([min(Y_train), max(Y_train)], [min(Y_train), max(Y_train)],
                'k--', color = 'black', lw=2)
axes[0, 0].set_title('Valor predicho vs valor real', fontsize = 10, fontweight =
axes[0, 0].set_xlabel('Real')
axes[0, 0].set_ylabel('Predicción')
axes[0, 0].tick_params(labelsize = 7)

axes[0, 1].scatter(list(range(len(Y_train))), residuos_train,
                   edgecolors=(0, 0, 0), alpha = 0.4)
axes[0, 1].axhline(y = 0, linestyle = '--', color = 'black', lw=2)
axes[0, 1].set_title('Residuos del modelo', fontsize = 10, fontweight = "bold")
axes[0, 1].set_xlabel('id')
axes[0, 1].set_ylabel('Residuo')
axes[0, 1].tick_params(labelsize = 7)
```

```
sns.histplot(
    data    = residuos_train,
    stat    = "density",
    kde     = True,
    line_kws= {'linewidth': 1},
    color   = "firebrick",
    alpha   = 0.3,
    ax      = axes[1, 0]
)

axes[1, 0].set_title('Distribución residuos del modelo', fontsize = 10,
                     fontweight = "bold")
axes[1, 0].set_xlabel("Residuo")
axes[1, 0].tick_params(labelsize = 7)


sm.qqplot(
    residuos_train,
    fit   = True,
    line  = 'q',
    ax    = axes[1, 1],
    color = 'firebrick',
    alpha = 0.4,
    lw    = 2
)
axes[1, 1].set_title('Q-Q residuos del modelo', fontsize = 10, fontweight = "bol
axes[1, 1].tick_params(labelsize = 7)

axes[2, 0].scatter(prediccion_train, residuos_train,
                   edgecolors=(0, 0, 0), alpha = 0.4)
axes[2, 0].axhline(y = 0, linestyle = '--', color = 'black', lw=2)
axes[2, 0].set_title('Residuos del modelo vs predicción', fontsize = 10, fontwei
axes[2, 0].set_xlabel('Predicción')
axes[2, 0].set_ylabel('Residuo')
axes[2, 0].tick_params(labelsize = 7)

# Se eliminan los axes vacíos
fig.delaxes(axes[2,1])

fig.tight_layout()
plt.subplots_adjust(top=0.9)
fig.suptitle('Diagnóstico residuos', fontsize = 12, fontweight = "bold");
```

```
C:\Users\Marti\AppData\Local\Temp\ipykernel_7008\99266934.py:12: UserWarning: col
or is redundantly defined by the 'color' keyword argument and the fmt string "k--
" (-> color='k'). The keyword argument will take precedence.
  axes[0, 0].plot([min(Y_train), max(Y_train)], [min(Y_train), max(Y_train)],
C:\Users\Marti\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.11_qbz5n2
kfra8p0\LocalCache\local-packages\Python311\site-packages\statsmodels\graphics\go
fplots.py:1045: UserWarning: color is redundantly defined by the 'color' keyword
argument and the fmt string "b" (-> color=(0.0, 0.0, 1.0, 1)). The keyword argume
nt will take precedence.
  ax.plot(x, y, fmt, **plot_style)
```

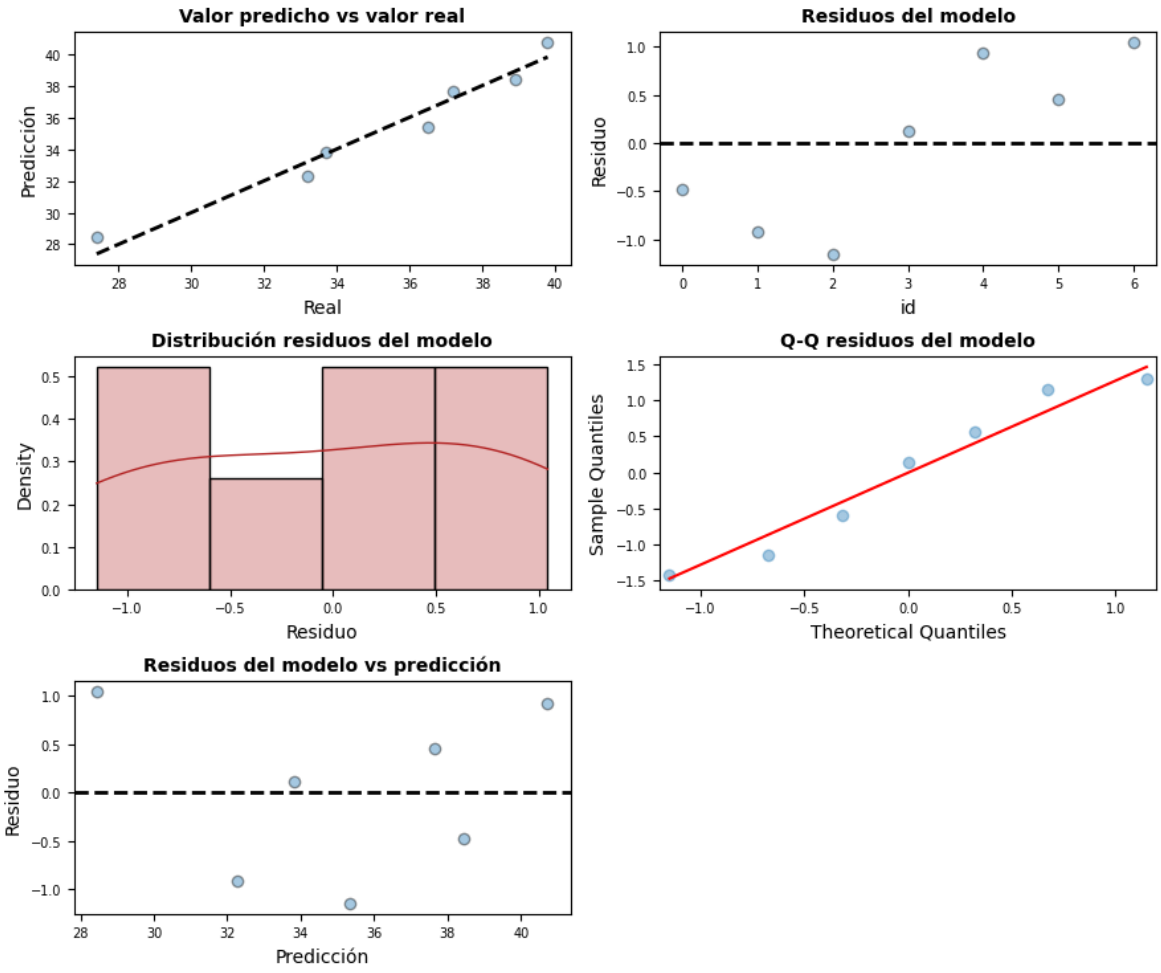

Es difícil hacer un diagnóstico debido a la poca cantidad de muestras que tenemos, de todas formas se puede ver que en cierta medida se están distribuyendo de manera aleatoria en torno al cero los residuos. Lo mismo se puede decir respecto a la variabilidad respecto al eje.

Esto nos deja que es posible una falta de homocedasticidd y de distribución normal.

d) ¿Qué información se puede obtener sobre la demanda de botellas de PPB a un 95 % cuando para los meses de Diciembre y Enero el distribuidor se plantea fijar un precio de la botella de 1.3 y 0.9 euros respectivamente?

In [ ]:
```
enero = [1.,1.3]
diciembre = [1.,0.9]
X_train_d = [enero, diciembre]
predicciones_train_d = modelo.get_prediction(exog=X_train_d).summary_frame(alpha
predicciones_train_d
```

Out[ ]:

	mean	mean_se	mean_ci_lower	mean_ci_upper	obs_ci_lower	obs_ci_upper
0	33.049346	0.415542	31.981163	34.117530	30.373368	35.725324
1	39.191176	0.517633	37.860559	40.521794	36.400050	41.982303

Aquí vemos que para enero (columna 0), se estima que la demanda de botellas estará entre 31981 y 34117 botellas a un 95% de probabilidad, y para diciembre (columna 1) su

rango será de 37860 a 40521 también para un 95% de probabilidad.

e) Ahora el distribuidor está interesado en fijar, para los próximos 6 meses, el precio de la botella que le proporcione unos ingresos máximos. Obtener una variable que recoja los ingresos durante los 10 meses analizados, siendo Z los ingresos en miles de euros para un mes en el que el precio de la botella de PPB es X.

Para ello, calculamos cuál ha sido el mes que más ingresos se ha tenido, calculando lo mismo como precio*botellas:

In [ ]:
```
Z = np.multiply(X, Y)
Z
```

Out[ ]:
```
array([44.82 , 36.955, 39.93 , 43.84 , 42.125, 31.84 , 37.2  , 44.4  ,
       41.975, 44.515])
```

f) Representar el diagrama de dispersión con la recta de regresión ajustada para Z en función de X. Calcular e interpretar las diferentes sumas de cuadrados y el coeficiente de determinación lineal entre Z y X. Extraer conclusiones.

In [ ]:
```
# División de los datos en train y test
# ==============================================================================
X_train, X_test, Z_train, Z_test = train_test_split(X, Z,
                                        # train_size   = 0.8,
                                        random_state = 1234
                                    )

# Creación del modelo utilizando matrices como en scikitlearn
# ==============================================================================
# A la matriz de predictores se le tiene que añadir una columna de 1s para el in
X_train = sm.add_constant(X_train, prepend=True)
modelo = sm.OLS(endog=Z_train, exog=X_train,)
modelo = modelo.fit()
print(modelo.summary())
modelo.conf_int(alpha=0.05)

# Predicciones con intervalo de confianza del 95%
# ==============================================================================
predicciones = modelo.get_prediction(exog = X_train).summary_frame(alpha=0.05)
predicciones['x'] = X_train[:, 1]
predicciones = predicciones.sort_values('x')

# Gráfico del modelo
# ==============================================================================
plt.scatter(X, Z, marker='o', color = "gray")
plt.plot(predicciones['x'], predicciones["mean"], linestyle='-', label="OLS", co
plt.plot(predicciones['x'], predicciones["mean_ci_lower"], linestyle='--', color
plt.plot(predicciones['x'], predicciones["mean_ci_upper"], linestyle='--', color
plt.fill_between(predicciones['x'], predicciones["mean_ci_lower"], predicciones[
plt.legend();
```

```
C:\Users\Marti\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.11_qbz5n2
kfra8p0\LocalCache\local-packages\Python311\site-packages\statsmodels\stats\statt
ools.py:74: ValueWarning: omni_normtest is not valid with less than 8 observation
s; 7 samples were given.
  warn("omni_normtest is not valid with less than 8 observations; %i "
```

OLS Regression Results

Dep. Variable:	y	R-squared:	0.814
Model:	OLS	Adj. R-squared:	0.777
Method:	Least Squares	F-statistic:	21.90
Date:	Fri, 10 Nov 2023	Prob (F-statistic):	0.00544
Time:	18:13:31	Log-Likelihood:	-14.266
No. Observations:	7	AIC:	32.53
Df Residuals:	5	BIC:	32.42
Df Model:	1		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	21.8264	3.934	5.548	0.003	11.713	31.940
x1	15.5519	3.324	4.679	0.005	7.009	24.095

Omnibus:	nan	Durbin-Watson:	1.154
Prob(Omnibus):	nan	Jarque-Bera (JB):	0.641
Skew:	-0.394	Prob(JB):	0.726
Kurtosis:	1.745	Cond. No.	9.50

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.

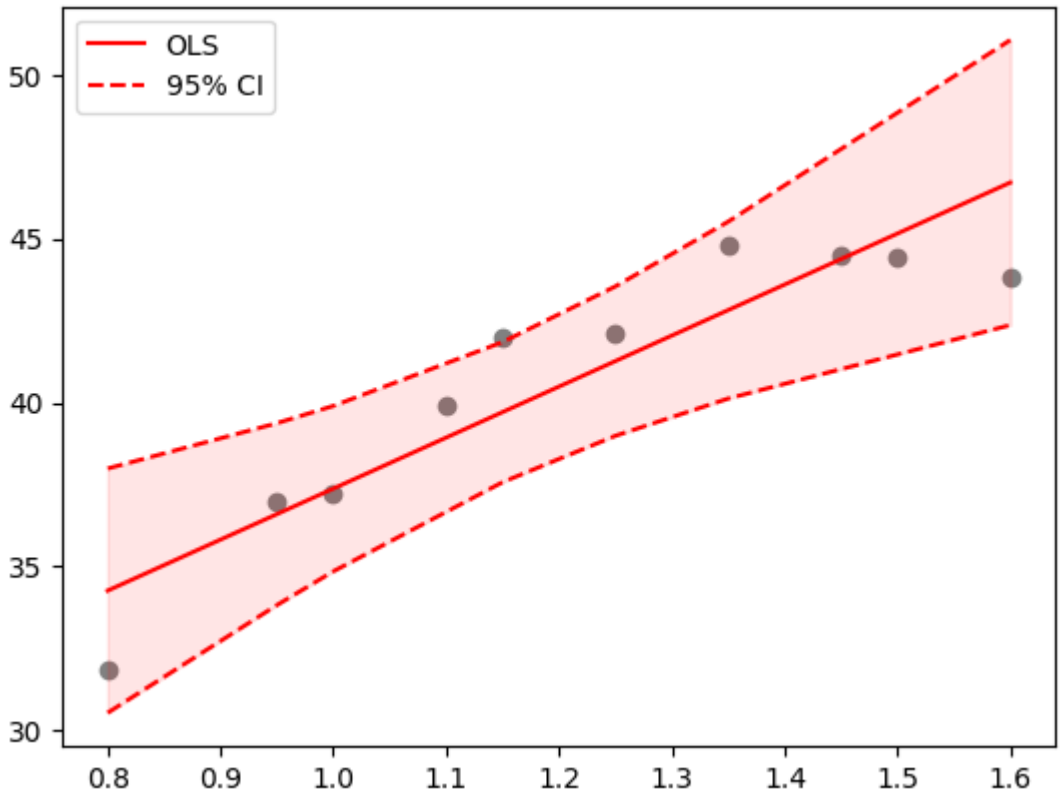

Vemos que el coeficiente de determinación lineal entre Z y X es cercano a 1, por lo que podemos deducir que la variable X explica bien los resultados de la variable Z. Pero, cabe destacar que el número es notablemente más bajo que el anterior, por no decir que cualitativamente se ve un desajuste de la recta respecto a la muestra.

g) Obtener la parábola de regresión mínimo-cuadrática de Z sobre X. Calcular e interpretar las diferentes sumas de cuadrados y el coeficiente de determinación

parabólica entre Z y X.

In [ ]:
```
polynomial_features= PolynomialFeatures(degree=2)
xp = polynomial_features.fit_transform(X_train)

modelo = sm.OLS(endog=Z_train, exog=xp,).fit()
print(modelo.summary())
predicciones = modelo.get_prediction(exog=xp).summary_frame(alpha=0.05)
predicciones['x'] = X_train[:, 1]
predicciones = predicciones.sort_values('x')
modelo.conf_int(alpha=0.05)

plt.scatter(X,Z)
plt.plot(predicciones['x'], predicciones["mean"], linestyle='-', label="OLS", co
plt.plot(predicciones['x'], predicciones["mean_ci_lower"], linestyle='--', color
plt.plot(predicciones['x'], predicciones["mean_ci_upper"], linestyle='--', color
plt.fill_between(predicciones['x'], predicciones["mean_ci_lower"], predicciones[
plt.legend();
```

```
C:\Users\Marti\AppData\Local\Packages\PythonSoftwareFoundation.Python.3.11_qbz5n2
kfra8p0\LocalCache\local-packages\Python311\site-packages\statsmodels\stats\statt
ools.py:74: ValueWarning: omni_normtest is not valid with less than 8 observation
s; 7 samples were given.
  warn("omni_normtest is not valid with less than 8 observations; %i "
```

OLS Regression Results

Dep. Variable:	y	R-squared:	0.980
Model:	OLS	Adj. R-squared:	0.969
Method:	Least Squares	F-statistic:	95.93
Date:	Fri, 10 Nov 2023	Prob (F-statistic):	0.000417
Time:	18:13:31	Log-Likelihood:	-6.5358
No. Observations:	7	AIC:	19.07
Df Residuals:	4	BIC:	18.91
Df Model:	2		
Covariance Type:	nonrobust		

	coef	std err	t	P>|t|	[0.025	0.975]
const	-5.3391	2.268	-2.354	0.078	-11.637	0.959
x1	-5.3391	2.268	-2.354	0.078	-11.637	0.959
x2	40.8171	5.836	6.994	0.002	24.613	57.021
x3	-5.3391	2.268	-2.354	0.078	-11.637	0.959
x4	40.8171	5.836	6.994	0.002	24.613	57.021
x5	-27.5596	4.841	-5.693	0.005	-41.000	-14.119

Omnibus:	nan	Durbin-Watson:	1.862
Prob(Omnibus):	nan	Jarque-Bera (JB):	0.575
Skew:	-0.237	Prob(JB):	0.750
Kurtosis:	1.678	Cond. No.	3.13e+18

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly specified.
[2] The smallest eigenvalue is 5.65e-36. This might indicate that there are strong multicollinearity problems or that the design matrix is singular.

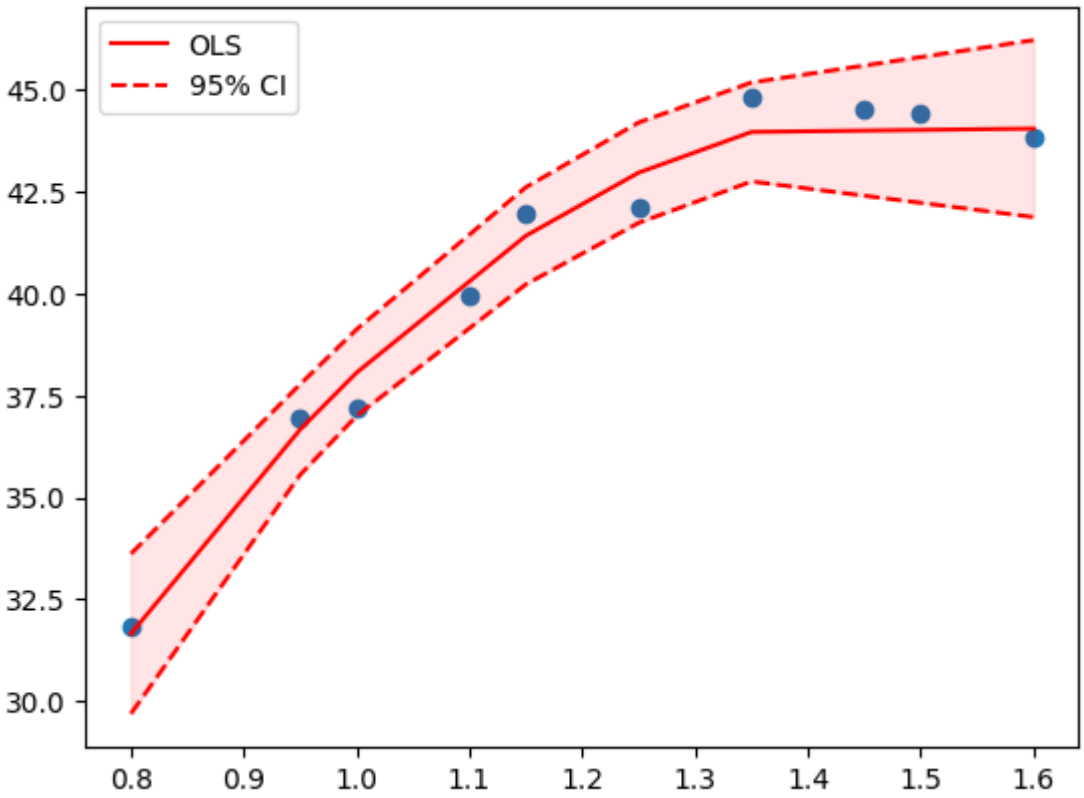

Aquí podemos ver que estas sumas de cuadrados hacen que nuestra predicción se aproxime mucho más a la realidad del modelo, al igual que un p-valor bajo.

h) Calcular para los próximos seis meses el precio de la botella que proporcione al distribuidor de unos ingresos máximos. Con dicho precio

a. ¿Cuál será la predicción y el intervalo de predicción al 95% de ingresos para cada mes?

b. ¿Qué información se puede obtener sobre los ingresos medios de un mes al 95% de confianza?

In [ ]:
```
predicciones
```

Out[ ]:

	mean	mean_se	mean_ci_lower	mean_ci_upper	obs_ci_lower	obs_ci_upper	x
4	31.651762	0.706650	29.689787	33.613738	28.658340	34.645185	0.80
0	36.662489	0.399902	35.552182	37.772796	34.143757	39.181221	0.95
5	38.057135	0.382617	36.994820	39.119449	35.559187	40.555082	1.00
2	41.414283	0.429306	40.222339	42.606228	38.858513	43.970054	1.15
3	42.963392	0.443471	41.732118	44.194666	40.389044	45.537740	1.25
1	43.961308	0.437293	42.747189	45.175427	41.395121	46.527495	1.35
6	44.044631	0.781848	41.873872	46.215390	40.910397	47.178865	1.60

Podemos ver que el valor máximo de la predicción corresponde al precio de 1.60, por lo que ese sería el precio que proporcionaría un beneficio máximo al cliente.

a. La predicción entonces sería de 44.044, con un intervalo de confianza del 95% [41.873872, 46.215390]

b. Podemos ver que tiene una cota inferior más baja que la cota inferior de otras predicciones, es decir, que su error estándar es mayor, por lo que podría escogerse otro valor para minimizar el riesgo. De todas formas, esta predicción mejoraría con una cantidad mayor de datos.

Ejercicio 2

INMOCASA es una empresa reconocida de compra-venta y alquiler de viviendas. El fichero Ventapisos.xlsx contiene información sobre 72 inmuebles y una serie de variables sobre los mismos como:

- Y: precio (en euros),
- X1: superficie (en metros cuadrados),
- X2: distancia al centro, en km
- X3: distancia a transporte público, en metros
- X4: Zona
- X5: Piscina (variable binaria donde 0 (1) es que el piso NO (SI) tiene piscina)
- X6: Garaje (variable binaria donde 0 (1) es que el piso NO (SI) tiene plaza de garaje)
- X7: Planta (variable discreta que indica la planta del edificio en la que se encuentra el piso)
- X8: numhab (variable discreta que indica el número de habitaciones que tiene la vivienda)
- X9: numbaños (variable discreta que indica el número de baños que tiene la vivienda)

a) Dibuja el gráfico matricial de las 10 variables. Calcula la matriz de correlaciones. Extrae conclusiones.

In [ ]:
```
ventapisos = pd.read_excel('Ventapisos.xlsx')
ventapisos
```

Out[ ]:

	Numpiso	zona	piscina	garage	precio	superficie	planta	distcentro	disttranspp
0	1	1	0	0	235000	65	2	0.0	
1	2	1	0	0	360000	70	10	0.0	
2	3	1	0	0	450760	94	6	0.0	
3	4	1	0	0	265000	55	3	0.0	
4	5	1	0	0	686400	150	9	0.0	
...	...	...	...	...	...	...	...	...	
67	68	7	0	1	372000	118	5	22.7	
68	69	7	1	1	438740	110	2	12.9	
69	70	7	1	1	438738	140	2	12.4	
70	71	7	1	1	870000	240	4	13.9	
71	72	7	1	1	364000	121	8	24.0	

72 rows × 11 columns

In [ ]:
```
sns.pairplot(ventapisos)
```

Out[ ]:
```
<seaborn.axisgrid.PairGrid at 0x23cf8dd9510>
```

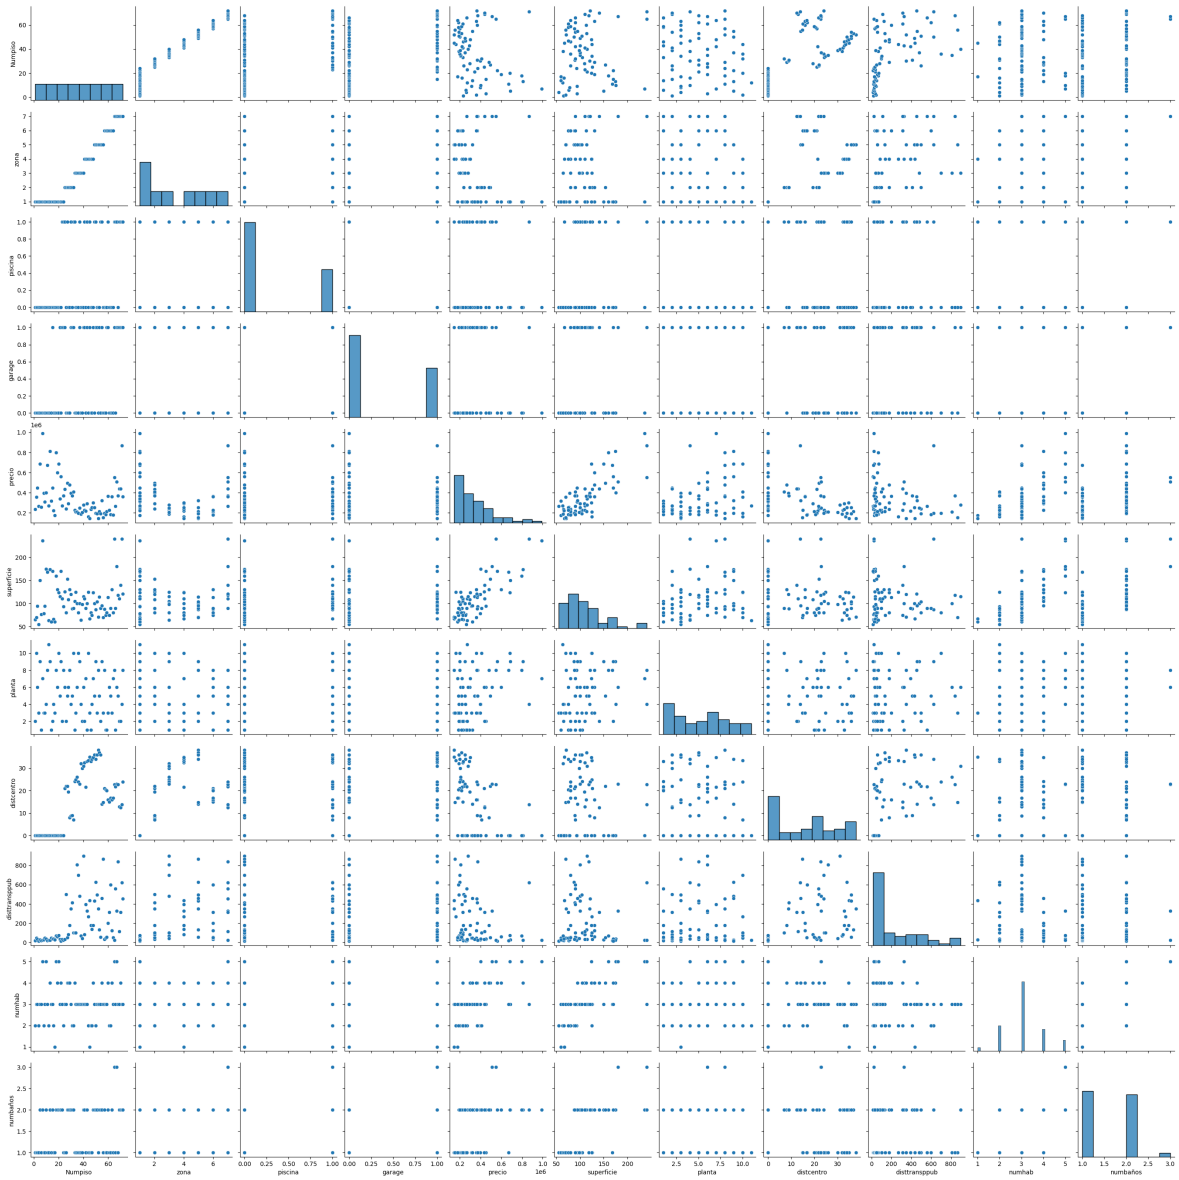

In [ ]:
```
#plt.matshow(df.corr())
sns.heatmap(ventapisos.corr(), annot=True)
```

Out[ ]: <Axes: >

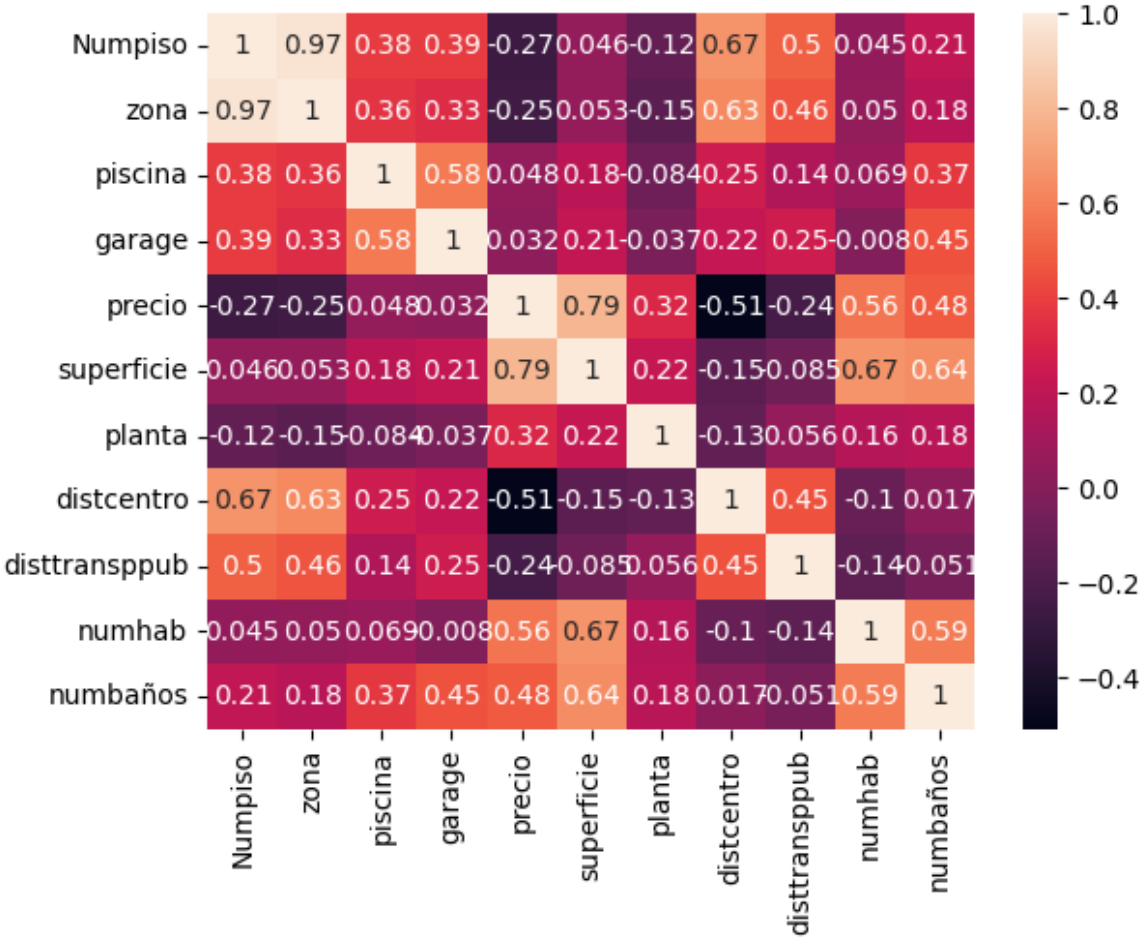

Podemos observar las distintas relaciones que existen de correlación entre las distintas variables Xi, de manera que podemos ver por ejemplo que zona está muy correlada con el número de piso, posiblemente debido a que en función de la zona los edificios son más o menos altos en función de la zona. Otra variable que vemos altamente correlada, esta vez de manera inversa es el precio con la distancia al centro, lo cual nos hace ver que a menor distancia al centro mayor es el precio de la vivienda, ya que estamos hablando de una relación inversa.

b) Calcula de manera razonada el modelo AS-RLS de Y sobre X1.

Interpreta sus parámetros.

In [ ]:
```
X_train, X_test, Y_train, Y_test = train_test_split(ventapisos['superficie'], ve
                                                    ## train_size   = 0.8,
                                                    random_state = 1234
                                                )

# Creación del modelo utilizando matrices como en scikitlearn
# ==============================================================================
# A la matriz de predictores se le tiene que añadir una columna de 1s para el in
X_train = sm.add_constant(X_train, prepend=True)
modelo = sm.OLS(endog=Y_train, exog=X_train,)
modelo = modelo.fit()
print(modelo.summary())
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                  precio   R-squared:                       0.561
Model:                             OLS   Adj. R-squared:                  0.553
Method:                  Least Squares   F-statistic:                     66.54
Date:                 Fri, 10 Nov 2023   Prob (F-statistic):           7.19e-11
Time:                         18:14:01   Log-Likelihood:                -705.64
No. Observations:                   54   AIC:                             1415.
Df Residuals:                       52   BIC:                             1419.
Df Model:                            1
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const        947.7144    4.4e+04      0.022      0.983   -8.73e+04    8.92e+04
superficie  3109.6819    381.225      8.157      0.000    2344.698    3874.665
==============================================================================
Omnibus:                        5.496   Durbin-Watson:                   2.364
Prob(Omnibus):                  0.064   Jarque-Bera (JB):                4.603
Skew:                           0.693   Prob(JB):                        0.100
Kurtosis:                       3.356   Cond. No.                         320.
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly
specified.
```

No se trata de un ajuste muy bueno, lo podemos ver en valores como la R^2 o el p-valor que son muy baja y muy alto respectivamente. También lo podemos ver en el error que es inusualmente alto.

c) Calcula de manera razonada el modelo AS-RLM de Y sobre X1 y X2.

Interpreta sus parámetros.

In [ ]:
```python
X_train, X_test, Y_train, Y_test = train_test_split(ventapisos[['superficie', 'd
                                        ## train_size   = 0.8,
                                        random_state = 1234
                                    )

# Creación del modelo utilizando matrices como en scikitlearn
# ==============================================================================
# A la matriz de predictores se le tiene que añadir una columna de 1s para el in
X_train = sm.add_constant(X_train, prepend=True)
modelo = sm.OLS(endog=Y_train, exog=X_train,)
modelo = modelo.fit()
print(modelo.summary())
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                 precio   R-squared:                       0.763
Model:                            OLS   Adj. R-squared:                  0.754
Method:                 Least Squares   F-statistic:                     82.01
Date:                Fri, 10 Nov 2023   Prob (F-statistic):           1.16e-16
Time:                        18:14:01   Log-Likelihood:                -689.04
No. Observations:                  54   AIC:                             1384.
Df Residuals:                      51   BIC:                             1390.
Df Model:                           2
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const       9.379e+04   3.56e+04      2.636      0.011    2.24e+04    1.65e+05
superficie  3116.0550    283.052     11.009      0.000    2547.805    3684.305
distcentro -5916.6768    898.866     -6.582      0.000   -7721.226   -4112.127
==============================================================================
Omnibus:                        2.335   Durbin-Watson:                   2.295
Prob(Omnibus):                  0.311   Jarque-Bera (JB):                1.615
Skew:                          -0.088   Prob(JB):                        0.446
Kurtosis:                       3.829   Cond. No.                         351.
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly
specified.
```

Esta aproximación es notablemente mejor que la anterior, pero de todas formas podemos ver también que el rango de valores es demasiado alto para que pueda sernos útil, así como el error estándar y los valores de la R^2 que se ajustan mejor pero no llegan a un valor que nos guste.

d) Calcula de manera razonada el modelo AS-RLM de Y sobre X1 y X3.

Interpreta sus parámetros.

In [ ]:
```
X_train, X_test, Y_train, Y_test = train_test_split(ventapisos[['superficie', 'd
                                        ## train_size   = 0.8,
                                        random_state = 1234
                                    )

# Creación del modelo utilizando matrices como en scikitlearn
# ==============================================================================
# A la matriz de predictores se le tiene que añadir una columna de 1s para el in
X_train = sm.add_constant(X_train, prepend=True)
modelo = sm.OLS(endog=Y_train, exog=X_train,)
modelo = modelo.fit()
print(modelo.summary())
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                 precio   R-squared:                       0.593
Model:                            OLS   Adj. R-squared:                  0.577
Method:                 Least Squares   F-statistic:                     37.16
Date:                Fri, 10 Nov 2023   Prob (F-statistic):           1.11e-10
Time:                        18:14:01   Log-Likelihood:                -703.62
No. Observations:                  54   AIC:                             1413.
Df Residuals:                      51   BIC:                             1419.
Df Model:                           2
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const          2.875e+04   4.5e+04      0.639      0.526   -6.16e+04    1.19e+05
superficie     3105.9833    370.774      8.377      0.000    2361.624    3850.342
disttransppub  -123.4676     61.934     -1.994      0.052    -247.805       0.870
==============================================================================
Omnibus:                        2.891   Durbin-Watson:                   2.334
Prob(Omnibus):                  0.236   Jarque-Bera (JB):                2.023
Skew:                           0.442   Prob(JB):                        0.364
Kurtosis:                       3.344   Cond. No.                         996.
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly
specified.
```

En este apartado sucede lo mismo que en el apartado **b)**, donde tenemos un R^2 demasiado bajo y unos errores y rango muy altos, así como un p-valor demasiado alto.

e) Calcula de manera razonada el modelo AS-RLM de Y sobre X1 y X7.

Interpreta sus parámetros.

In [ ]:
```
X_train, X_test, Y_train, Y_test = train_test_split(ventapisos[['superficie', 'N
                                                    ## train_size   = 0.8,
                                                    random_state = 1234
                                                )

# Creación del modelo utilizando matrices como en scikitlearn
# ==============================================================================
# A la matriz de predictores se le tiene que añadir una columna de 1s para el in
X_train = sm.add_constant(X_train, prepend=True)
modelo = sm.OLS(endog=Y_train, exog=X_train,)
modelo = modelo.fit()
print(modelo.summary())
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                 precio   R-squared:                       0.668
Model:                            OLS   Adj. R-squared:                  0.654
Method:                 Least Squares   F-statistic:                     51.19
Date:                Fri, 10 Nov 2023   Prob (F-statistic):           6.39e-13
Time:                        18:14:01   Log-Likelihood:                -698.16
No. Observations:                  54   AIC:                             1402.
Df Residuals:                      51   BIC:                             1408.
Df Model:                           2
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const       7.212e+04   4.25e+04      1.697      0.096   -1.32e+04    1.57e+05
superficie  3379.9003    341.752      9.890      0.000    2693.805    4065.996
Numpiso    -2792.0697    691.808     -4.036      0.000   -4180.933   -1403.207
==============================================================================
Omnibus:                        1.037   Durbin-Watson:                   2.509
Prob(Omnibus):                  0.595   Jarque-Bera (JB):                0.409
Skew:                           0.128   Prob(JB):                        0.815
Kurtosis:                       3.341   Cond. No.                         368.
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly
specified.
```

Seguimos mejorando respecto al apartado anterior, pero no conseguimos que se trate de un valor bueno pese a todo, su estadístico F es muy alto, así como su error estándar. También podemos ver que su R^2 ajustado no es muy alto, por lo que no nos vale esta hipótesis tampoco.

f) Siguiendo las indicaciones de la web https://dataaspirant.com/stepwise-regression/ proporciona el modelo AS-RLM con selección de variables que utilizarías en el futuro.

Interpreta dicho modelo

In [ ]:
```
X_train, X_test, Y_train, Y_test = train_test_split(ventapisos[['superficie', 'd
                                                    ## train_size   = 0.8,
                                                    random_state = 1234
                                                )

# Creación del modelo utilizando matrices como en scikitlearn
# ==============================================================================
# A la matriz de predictores se le tiene que añadir una columna de 1s para el in
X_train = sm.add_constant(X_train, prepend=True)
modelo = sm.OLS(endog=Y_train, exog=X_train,)
modelo = modelo.fit()
print(modelo.summary())
```

```
                            OLS Regression Results
==============================================================================
Dep. Variable:                 precio   R-squared:                       0.763
Model:                            OLS   Adj. R-squared:                  0.754
Method:                 Least Squares   F-statistic:                     82.01
Date:                Fri, 10 Nov 2023   Prob (F-statistic):           1.16e-16
Time:                        18:14:01   Log-Likelihood:                -689.04
No. Observations:                  54   AIC:                             1384.
Df Residuals:                      51   BIC:                             1390.
Df Model:                           2
Covariance Type:            nonrobust
==============================================================================
                 coef    std err          t      P>|t|      [0.025      0.975]
------------------------------------------------------------------------------
const       9.379e+04   3.56e+04      2.636      0.011    2.24e+04    1.65e+05
superficie  3116.0550    283.052     11.009      0.000    2547.805    3684.305
distcentro -5916.6768    898.866     -6.582      0.000   -7721.226   -4112.127
==============================================================================
Omnibus:                        2.335   Durbin-Watson:                   2.295
Prob(Omnibus):                  0.311   Jarque-Bera (JB):                1.615
Skew:                          -0.088   Prob(JB):                        0.446
Kurtosis:                       3.829   Cond. No.                         351.
==============================================================================

Notes:
[1] Standard Errors assume that the covariance matrix of the errors is correctly
specified.
```

Aquí, habiendo hecho una selección de parámetros más razonada, podemos ver que hay valores mucho más razonables de cara a un ajuste de regresión lineal múltiple. El R^2 es relativamente alto, su p-valor bajo y su error estándar también. Esto nos deja con que es la mejor estimación que hemos hecho hasta la fecha.

g) Han llegado dos pisos A y B a INMOCASA con los siguientes valores para las variables:

	X1	X2	X3	X7
A	100	2	200	7
B	300	0.5	400	4

Calcula de manera razonada las diferentes predicciones del precio de venta de esos pisos, dando la máxima información posible.

In [ ]:
```
# X_train = pd.DataFrame({'const': [1.0,1.0], 'superficie': [100,300], 'distcent
X_train = pd.DataFrame({'const': [1.0,1.0], 'superficie': [100,300], 'distcentro
predicciones = modelo.get_prediction(exog = X_train).summary_frame(alpha=0.05)
predicciones
```

Out[ ]:

	mean	mean_se	mean_ci_lower	mean_ci_upper	obs_ci_lower	obs_ci_u
0	3.935613e+05	17249.917931	358930.595155	4.281919e+05	216187.589711	5.709349e
1	1.025647e+06	57431.483387	910348.758357	1.140946e+06	816946.815758	1.234348e

Podemos ver que los valores que nos da para las dos casas son:

- A: un valor de casi 400.000€ y un rango de valores [360.000, 433.000]
- B: un valor de 1.000.000€ y un rango de valores [913.944, 1.156.558] Ambos valores estimados con una probabilidad del 95%.

Esto cualitativamente encaja por lo que hemos visto, ya que el piso A es más pequeño y a mayor distancia del centro, lo cual, según las correlaciones que hemos visto, indicaría un precio menor que el piso B.